

Bases de Datos 2

Teoría 10


Federico Orlando

Data warehouse

Data warehouse

Motivación

¿Qué fuentes de datos existen en una organización?



¿Cómo obtenemos información esencial para el negocio de estas fuentes tan diversas?

Data warehouse

Historia

Según W. H. Inmon (considerado por muchos el padre del concepto), un data warehouse es un conjunto de datos orientados por temas, integrados, variantes en el tiempo y no volátiles, que tienen por objetivo dar soporte a la toma de decisiones.

Según Ralph Kimball (considerado el principal promotor del enfoque dimensional para el diseño de almacenes de datos), un data warehouse es una copia de los datos transaccionales específicamente estructurada para la consulta y el análisis.

Data warehouse

Definición

¿Qué es un Data Warehouse? ¿Es un tipo de Base de Datos?

Un **Data Warehouse (almacén de datos)** es un sistema que se utiliza para almacenar en un único repositorio grandes volúmenes de datos que provienen de múltiples fuentes de datos de la organización. A su vez, se encuentra altamente estructurado proporcionando una visión global, común e integrada de los datos, independientemente de cómo se vayan a utilizar posteriormente los mismos.

Está diseñado específicamente para el análisis y la generación de informes, no para el procesamiento de transacciones del día a día.

Data warehouse

Características

- *Integración*
- *Consistencia*
- *Variable en el tiempo*
- *No volátil*
- *Organización temática*

Integración: Combina datos de diferentes fuentes como bases de datos operativas, hojas de cálculo y otras fuentes externas..

Consistencia: Los datos se normalizan y se convierten a un formato común para garantizar su precisión y coherencia

Variable en el tiempo: Contiene datos históricos, permitiendo analizar tendencias a lo largo del tiempo.

No volátil: Una vez que los datos se almacenan, no se modifican. Se usan solo para consulta y análisis.

Organización temática: Organizado en torno a temas clave como ventas, clientes, productos, etc.

Data warehouse

Funciones y uso

- *Buisness Intelligence*
- *Informes y/o reportes gerenciales*
- *Decisiones basadas en datos*
- *Análisis de tendencias y comportamientos*
- *Data mining*
- *Machine Learning*

Data warehouse

Componentes

- *Data Sources*
- *Herramientas de ETL*
- *Metadata*
- *Base de datos*
- *Herramientas de consulta y análisis*

Data Sources: Orígenes de datos, sistemas transaccionales, archivos, redes sociales, etc.

Herramientas de ETL: Herramientas que realizan la Extracción, Transformación y Carga de datos. En la fase de Transformación se limpian los datos.

Metadata: Los datos de los datos. Describen a los datos.

Base de datos: donde se alojan los datos en la fase de carga del proceso de ETL.

Herramientas de consulta y análisis: Tableau, Power BI, Qlik, etc.


Data warehouse

ETL

- *Extracción*
- *Transformación*
- *Carga (Load)*

Data warehouse

Arquitectura



Data warehouse

Bases de Datos vs Data Warehouse

Bases de Datos	Data Warehouse
Orientada a transacciones	Orientado a consultas
Operativa	Análisis y toma de decisiones estratégicas
Proceso puntual	Proceso batch masivo
Estabilidad	Dinámica
Datos desagregados	Distintos niveles de agregación
Dato actual	Evolución del dato
Usuario de perfil bajo	Usuarios de perfil alto
Datos relacionados con lo operativo	Datos relacionados con el negocio

Data warehouse

Tablas

HECHOS (medidas): Son el objeto de los análisis y están relacionados con las dimensiones. Son tablas muy grandes y suelen estar desnormalizadas o en 3FN. A menudo incluyen diferentes agregaciones como máximo, mínimo, media, etc.

Almacena datos cuantitativos o numéricos sobre un proceso de negocio, como ventas, compras, o incidencias para su análisis.

Una tabla de hechos suele tener dos tipos de columnas: claves foráneas para tablas de dimensiones y medidas, que contienen datos numéricos. Una tabla de hechos puede contener datos de hechos a nivel de detalle o agregado.

Data warehouse

Tablas

DIMENSIONES: Representan factores por los que se analiza una determinada área de negocio, describiendo y dando contexto a los datos numéricos. Son pequeñas y usualmente están desnormalizadas.

Las dimensiones responden preguntas como: ¿Quién? ¿Qué? ¿Cuándo? ¿Dónde? ¿Cómo?

Los hechos contiene los datos de estudio y las dimensiones contienen los metadatos sobre dichos hechos.

Si la información necesita disponer de varios niveles de granularidad se crean jerarquías con las dimensiones. Por ejemplo la jerarquía fecha podría ser «día – semana – mes – trimestre – año». Las jerarquías de las dimensiones presentan relaciones n-1 de manera que un valor de un nivel sólo puede ser agrupado por un único valor de cada nivel inmediatamente superior en la jerarquía.


Data warehouse

Modelos

- *Estrella*
- *Copo de Nieve*
- *Galaxia o Constelación*

Data warehouse

Modelo Estrella




En el centro una sola tabla de hechos

En los picos tablas dimensión.

Las tablas de dimensiones no están unidas entre sí.

Data warehouse

Modelo Estrella



Data warehouse

Modelo Estrella

PROS

- *Es el más simple de todos los modelos, esto lo hace muy fácil de integrar en la organización, ya que es fácilmente comprensible.*
- *Es un modelo que tiene muy buen rendimiento en las consultas, ya que solamente involucramos un join entre los datos.*

Data warehouse


Modelo Estrella

CONTRAS

- *La escalabilidad puede ser peor, ya que existe un uso más ineficiente del almacenamiento.*
- *Trabajar con tablas desnormalizadas y redundancia de datos hace que el tamaño de la tabla pudiera ser grande y se produzca un tiempo relativamente largo de carga de datos en tablas de dimensiones.*

Data warehouse


Modelo Copo de nieve (Snowflake)



Es una extensión del modelo estrella donde las dimensiones se relacionan con otras dimensiones.

Data warehouse

Modelo Copo de nieve (Snowflake)



Es una extensión del modelo estrella donde las dimensiones se relacionan con otras dimensiones.

Data warehouse

Modelo Copo de nieve

PROS

- *Permite generar más contexto alrededor de una tabla de hechos.*
- *Trabajas con tablas normalizadas, se evita la redundancia de datos añadiendo más capas de contexto.*

Data warehouse


Modelo Copo de Nieve

CONTRAS

- *El código es mucho más complejo ya que pasamos a dos niveles de join a la hora de trabajar con una dimensión.*

Data warehouse

Modelo Galaxia



Hay más de una tabla de hechos que comparten dimensiones. Es una colección de estrellas. Las dimensiones compartidas se denominan conformadas.

Data warehouse

Data Mart

Un Data Mart es un subconjunto de los datos del Data Warehouse orientado a un área específica con el objetivo de responder a determinados análisis o necesidades de dicha área, como pueden ser ventas o finanzas.

En un Data Mart independiente, los datos pueden recopilarse directamente de las fuentes. Tiene diversas funciones como organizar la información para posteriormente analizarla, realizar indicadores (KPI), evaluar los objetivos del sector que se está analizando, etc. El objetivo es realizar un análisis detallado sobre lo que ocurre en un negocio.

Data warehouse

Data Lake

- *Es un repositorio orientado a almacenar gran cantidad de datos, tanto estructurados como sin estructurar.*
- *Permite almacenar los datos tal cual vienen sin necesidad de ser transformados.*
- *Ejecuta diferentes tipos de análisis, dashboards y visualizaciones, además de generar procesos de big data, análisis en tiempo real y de Machine Learning que facilitan la toma de decisiones.*

SIG

Sistema de Información Geográfica



Definición

¿Qué es un SIG?

Es un Sistema de Información compuesto por hardware, software, procedimientos, datos y equipo humano

¿Qué permiten los procedimientos?

- capturar
- almacenar
- analizar
- visualizar

datos que tienen una ubicación en el espacio



Usos de SIG

Tipos de aplicaciones



Aplicaciones científicas: ciencias medioambientales, desarrollo de modelos empíricos, modelización cartográfica, modelos dinámicos, teledetección y uso de imágenes satélite

Labores relacionadas con la gestión:



implementación de técnicas de cartografía automatizada, integración en el Catastro, planificación de espacios protegidos, ordenación y planificación territorial y urbana, estudios de impacto ambiental, evaluación y análisis de recursos, seguimiento de determinadas acciones o consecuencias de las mismas, etc.

Aplicaciones empresariales: labores de marketing, implementación de estrategias de distribución optimizadas, localización de áreas de interés según el

comportamiento y hábitos de los potenciales clientes

Formas de representación

Modelos




Formas de representación

Modelo Vectorial

Representa el espacio mediante geometrías definidas por coordenadas.

- **Puntos:** ubicaciones específicas (ej. pozos, ciudades).
- **Líneas:** elementos lineales (ej. rutas, ríos).
- **Polígonos:** áreas cerradas (ej. provincias, lagos).



Es ideal para representar objetos discretos y bien definidos.

Se centra en la precisión de la ubicación.


La estructura de este modelo es muy simple y fácil de comprender. El modelo de datos es el mapa expresado en coordenadas cartesianas. Los archivos de datos de las coordenadas (X,Y) es actualmente la estructura de datos, la forma en que los datos espaciales son guardados. A pesar de que todas las características espaciales sean guardadas, las relaciones espaciales

entre estas no son codificadas.

Formas de representación

Modelo Vectorial Topológico

- arco
- nodo



Es el método más usado para codificar relaciones espaciales en un GIS. La topología es el método matemático usado para definir relaciones espaciales. La forma particular de este modelo, es llamada arco-nodo. La entidad básica es el arco, una serie de puntos que comienzan y terminan en un nodo. Un nodo es un punto de intersección donde dos o más arcos se encuentran. Un nodo aislado, que no está conectado a ningún arco, representa un punto. Un polígono está compuesto por una cadena cerrada de arcos que representan los límites del área.


Formas de representación

Modelo Raster

Representa el espacio como una matriz de celdas (píxeles).

- Cada celda tiene un valor (ej. altitud, temperatura, uso del suelo).
- Muy usado en imágenes satelitales y análisis ambiental.

Es mejor para fenómenos continuos.



Se centra en las propiedades del espacio más que en la precisión de la localización.

Este modelo consta de una grilla regular de celdas rectangulares o cuadradas. La ubicación de cada celda o píxel (de la imagen) es definida por los números de columnas y filas. Su forma de proceder es dividir la zona afectada de la base de datos en una retícula de pequeñas celdas y atribuir un valor numérico a cada celda como representación de su valor temático. El tamaño de la celda es constante y se conoce la posición en coordenadas del centro de una de las celdas, por lo tanto se puede decir que todas las celdas están georreferenciadas.

El valor asignado a la celda indica el valor del atributo

representado. Cada celda en un archivo raster tiene asignado un único valor. Entonces diferentes atributos son guardados en diferentes archivos. El modelo raster cubre la totalidad del espacio. Un conjunto de celdas, junto con sus valores se denomina capa raster.

Es posible que varias celdas contengan el mismo valor que sus celdas vecinas. Para evitar esta redundancia significativa de información es posible usar métodos de compresión como run-length encoding o quadrees.

Formas de representación

Raster vs Vectorial: Ventajas

Modelo Raster	Modelo Vector
✓ Es una estructura de datos simple ✓ Algunas operaciones son fáciles y eficientemente implementadas. ✓ Alta variabilidad espacial es eficientemente representada ✓ Este formato es más o menos requerido para manipulación eficiente de imágenes digitales ✓ Útil para grandes extensiones con poca precisión de propiedades espaciales	✓ Provee una estructura de datos más compacta ✓ Provee codificación eficiente de topologías y como resultado más eficiente implementación de operaciones que requieren información topológica ✓ Es más apropiado para soportar gráficos, más aproximado a mapas dibujados a mano. Cartografía de calidad ✓ Menor espacio de almacenamiento ✓ Define fronteras explícitamente ✓ Resultado más exacto en el cálculo de distancias

Formas de representación

Raster vs Vectorial: Desventajas

✓Modelo Raster	✓Modelo Vector
✓La estructura es menos compacta. Las técnicas de compresión de datos pueden sobrellevar este problema ✓Relaciones topológicas son más difíciles de representar ✓La salida de gráficos es menos agradable estéticamente porque los bordes tienden a tener apariencia de bloque más que suaves líneas de mapas dibujados a mano. ✓Para evaluar si hay objetos superpuestos hay que fijarse en 2 o más capas. ✓Desperdicio de espacio de almacenamiento para datos espaciales muy esparcidos	✓Es una estructura más compleja que el raster simple ✓Algunas operaciones son más difíciles de implementar ✓La representación de datos espaciales de alta variabilidad es ineficiente ✓Manipulación de imágenes digitales no pueden ser realizadas de forma efectiva.

BBDD SIG

Bases de datos espaciales más populares

- **PostgreSQL + PostGIS:** Un estándar en una base de datos de código abierto utilizado para almacenar grandes cantidades de datos vectoriales, frecuentemente integrado con QGIS para aplicaciones empresariales.
- **Oracle Spatial and Graph:** Ampliamente utilizado para la gestión espacial empresarial a gran escala, como el manejo de grandes volúmenes de datos de sensores remotos y datos ráster.
- **Microsoft SQL Server Spatial:** Admite datos tanto geométricos como geográficos.
- **Esri File Geodatabase:** Un formato de base de datos propietario basado en carpetas ampliamente utilizado.

BBDD SIG

Funcionalidades de una BD SIG

- Almacenamiento y organización de datos
- Análisis espacial
- Visualización de datos
- Datos compartidos y colaboración
- Mantenimiento y actualización de datos

Almacenamiento y organización de datos: Las bases de datos SIG permiten el almacenamiento y la organización eficientes de datos espaciales y de atributos, lo que facilita a los usuarios la gestión eficaz de grandes volúmenes de información geográfica. Los datos se estructuran de forma que se facilita su rápida recuperación y análisis según criterios espaciales y de atributos.

Análisis espacial: Las bases de datos SIG admiten una amplia gama de operaciones de análisis espacial, incluyendo superposición, análisis de zonas de influencia, análisis de proximidad, consultas espaciales y análisis de redes. Estas capacidades analíticas permiten a los usuarios obtener información valiosa a

partir de datos espaciales y tomar decisiones fundamentadas.

Visualización de datos: Las bases de datos SIG permiten visualizar datos espaciales mediante mapas, gráficos y otras representaciones gráficas. La visualización desempeña un papel fundamental en la comunicación de patrones, relaciones y tendencias espaciales a las partes interesadas, facilitando una mejor comprensión y toma de decisiones.

Datos compartidos y colaboración: Las bases de datos SIG facilitan compartir datos y la colaboración entre múltiples usuarios y organizaciones. Mediante interfaces web, API y formatos de datos estandarizados, los datos SIG pueden ser accedidos, intercambiados e integrados en diferentes plataformas y aplicaciones.

Mantenimiento y actualización de datos: Las bases de datos SIG permiten realizar actividades de mantenimiento de datos, como la edición, validación y control de versiones. Los usuarios pueden actualizar los datos espaciales y de atributos para reflejar los cambios en el mundo real, garantizando así la precisión y la actualidad de la información en la base de datos.

Índices espaciales

Volumen de Datos

Un índice espacial es utilizado por una base de datos espacial para optimizar las consultas espaciales, implementando métodos de acceso espacial. Las bases de datos utilizan índices para buscar valores rápidamente ordenando los datos de forma lineal (por ejemplo, alfabética); sin embargo, esta forma de indexar datos no es óptima para consultas espaciales en espacios bidimensionales o tridimensionales. En cambio, las bases de datos espaciales utilizan un índice espacial diseñado específicamente para la ordenación multidimensional.

- **Árbol R:** Método predeterminado en bases de datos como PostGIS y Oracle, que organiza los objetos en cuadros delimitadores jerárquicos.
- **Grilla:** Tesela el mundo en celdas regulares y jerárquicas (p. ej., Geohash, H3).
- **Quadtree:** Divide recursivamente el espacio 2D en cuatro cuadrantes, adecuado para conjuntos de datos dinámicos.

Capacidades

- **Soporte de tipos de datos espaciales:** Incluye tipos como geometría y geografía, que permiten almacenar coordenadas espaciales y atributos geográficos.
- **Soporte para datos vectoriales:** almacene diferentes tipos de datos espaciales, como puntos, líneas, polígonos y multigeometrías, tanto en datos 2D como 3D.
- **Soporte de datos ráster:** almacenamiento y procesamiento de datos ráster, como datos de elevación y datos meteorológicos.
- **Funciones espaciales:** Proporciona una amplia gama de funciones para realizar cálculos espaciales, como distancia, intersección, contención y más. Extensiones como las de topología y redes (pgrouting).
- **Indexación espacial:** Utiliza índices GiST (Generalized Search Tree) para mejorar el rendimiento de las consultas espaciales.
- **Cumplimiento de estándares OGC:** Sigue los estándares del Open Geospatial Consortium (OGC), lo que garantiza interoperabilidad con otras herramientas y sistemas geoespaciales.
- **Geocodificación y geocodificación inversa:** Funciones para geocodificación y geocodificación inversa.
- **Integración:** PostGIS se integra fácilmente con otras herramientas y sistemas GIS, como QGIS, R, GeoPandas, ArcGIS, Tableau o GeoServer

PostGIS

Tipos de datos geométricos

- **POINT** (Punto): Representa una única coordenada de ubicación (X, Y). Muy utilizado para localizaciones discretas.
- **LINESTRING** (Línea): Secuencia de puntos conectados por segmentos rectos.
- **POLYGON** (Polígono): Representa un área cerrada con un límite exterior (anillo) y puede contener agujeros en su interior.

Colecciones y Multigeometrías: Se usan cuando un registro debe agrupar múltiples objetos de la misma o distinta clase bajo una misma fila.

- **MULTIPOINT**: Colección de puntos.
- **MULTILINESTRING**: Colección de líneas.
- **MULTIPOLYGON**: Colección de polígonos.
- **GEOMETRYCOLLECTION**: Colección de cualquier combinación de los tipos anteriores.

https://postgis.net/docs/manual-3.6/using_postgis_dbmanagement.html#RefObject

PostGIS

Funciones de relación espacial

Evalúan cómo interactúan dos o más objetos espaciales y devuelven un valor booleano (true o false).

- **ST_Intersects:** Devuelve verdadero si dos geometrías comparten al menos un punto en común.
- **ST_Contains:** Verifica si una geometría está completamente contenida dentro de otra.
- **ST_Within:** Comprueba si la primera geometría está completamente dentro de la segunda.
- **ST_Touches:** Devuelve verdadero si dos geometrías comparten un borde o un vértice, pero no se superponen en su interior.
- **ST_Overlaps:** Evalúa si dos geometrías de la misma dimensión se intersectan pero no se incluyen totalmente la una en la otra

tienes una capa de ciudades y una de restaurantes:
Usas **ST_Contains** cuando el primer argumento es el contenedor:

"Encuentra todas las ciudades que contienen al restaurante Pepito"

ST_Contains(ciudad,\restaurant)

Usas **ST_Within** cuando el primer argumento es el elemento que está dentro:

"Encuentra todos los restaurantes que están dentro de la ciudad de Buenos Aires"

ST_Within(restaurant,ciudad)

PostGIS

Funciones de análisis métrico y geométrico

Permiten calcular medidas, dimensiones, áreas y distancias exactas sobre la Tierra o el plano cartesiano.

- **ST_Distance:** Calcula la distancia mínima en metros o unidades del SRID entre dos geometrías.
- **ST_Area:** Devuelve el área de un polígono o multipolígono.
- **ST_Length:** Devuelve la longitud de una línea o multilínea.
- **ST_Buffer:** Genera un polígono de área de influencia alrededor de una geometría a una distancia determinada.
- **ST_Centroid:** Calcula el centro geométrico de un polígono o conjunto de puntos

PostGIS

Funciones de agregación

Procesan múltiples filas de datos espaciales para agruparlas u obtener una sola entidad geográfica.

- **ST_Union:** Combina múltiples geometrías en una sola geometría compleja (disuelve bordes compartidos en polígonos).
- **ST_Collect:** Agrupa geometrías en una colección (multi-geometría) sin unir las físicamente ni disolver fronteras